# 난임 환자 임신 성공 여부 예측 AI 모델링 미니 프로젝트

환자 & 시술 데이터 활용

데이터 기반 의사결정

머신러닝 파이프라인 구축

**BAIB (3조)**

여은지 강재우 김설아 김지영 양승현

# 프로젝트 개요 및 목표

난임 치료 효율성 향상을 위한 AI 예측 모델링

## 이진 분류 모델 구축



- 환자의 건강 지표 및 시술 데이터를 학습
- 임신 성공(1)과 실패(0)를 정확히 판별
- 지도학습 기반의 고도화된 머신러닝 엔진 구현

## 데이터 인사이트 도출



- 데이터 시각화를 통한 주요 상관관계 파악
- 통계적으로 유의미한 주요 변수(Feature) 식별
- 데이터 중심(Data-centric)의 의사결정 지원

## 분석 기반 및 성능 최적화



- 예측 모델 개발을 위한 체계적 분석 파이프라인 마련
- 하이퍼파라미터 튜닝을 통한 모델 성능 극대화
- 실험의 재현성 및 확장성 확보

## 치료 효율성 및 환자 지원



- 난임 치료의 효율성을 증대시키는 기술적 기여
- 환자 맞춤형 시술 성공 가능성 정보 제공
- 의료진의 보조적 진단 도구로써의 활용 가치

# 피처 엔지니어링: 데이터 그룹화 전략

연관성 높은 변수들을 4개 그룹으로 분류하여 파생변수 생성 및 분석 효율 극대화

## Group 1: 시술 과정 및 타임라인

- 임신 시도/경과 연수 및 시술 단계별 경과일(해동, 채취, 이식 등)
- 착상 전 유전 검사(PGD, PGS) 및 유전 진단 여부
- 배란 자극 및 유도 유형, 동결/신선/기증 배아 사용 여부
- 단일 배아 이식 등 특정 시술 유형 정보

## Group 2: 난자 및 배아 수량/과정

- 총 생성/이식/저장/해동 배아 수 및 미세주입 관련 데이터
- 수집/저장/혼합된 신선 난자 수 및 정자 출처(파트너/기증자)
- 배아 생성 주요 이유 및 대리모 여부
- 시술 유형 전반에 걸친 수량 지표

## Group 3: 불임 원인 및 요인 분석

- 남성/여성/부부별 주/부 불임 원인 분류
- 질환별 요인: 난관 질환, 배란 장애, 자궁내막증, 자궁경부 문제
- 정자 상태: 농도, 운동성, 형태, 면역학적 요인
- 불명확한 원인 포함 피처 전체

## Group 4: 환자 이력 및 인적 정보

- 시술 당시 나이 및 시술 시기 코드
- 총 시술/임신/출산 횟수 (IVF, DI 별도 관리)
- 난자 및 정자 출처, 기증자 나이 정보
- 클리닉 내 시술 이력 및 환자 ID

```python
group1_cols = [
    '임신 시도 또는 마지막 임신 경과 연수', '착상 전 유전 검사 사용 여부', 'PGD 시술 여부', 'PGS 시술 여부',
    '난자 해동 경과일', '배아 해동 경과일', '난자 채취 경과일', '난자 혼합 경과일', '배아 이식 경과일',
    '특정 시술 유형', '배란 자극 여부', '배란 유도 유형', '단일 배아 이식 여부',
    '착상 전 유전 진단 사용 여부', '동결 배아 사용 여부', '신선 배아 사용 여부', '기증 배아 사용 여부'
]

group2_cols = [
    '총 생성 배아 수', '미세주입된 난자 수', '미세주입에서 생성된 배아 수', '이식된 배아 수',
    '미세주입 배아 이식 수', '저장된 배아 수', '미세주입 후 저장된 배아 수', '해동된 배아 수',
    '해동 난자 수', '수집된 신선 난자 수', '저장된 신선 난자 수', '혼합된 난자 수',
    '파트너 정자와 혼합된 난자 수', '기증자 정자와 혼합된 난자 수', '배아 생성 주요 이유', '대리모 여부', '시술 유형'
]

group3_cols = [
    '남성 주 불임 원인', '남성 부 불임 원인', '여성 주 불임 원인', '여성 부 불임 원인',
    '부부 주 불임 원인', '부부 부 불임 원인', '불명확 불임 원인', '불임 원인 - 난관 질환',
    '불임 원인 - 남성 요인', '불임 원인 - 배란 장애', '불임 원인 - 여성 요인', '불임 원인 - 자궁경부 문제',
    '불임 원인 - 자궁내막증', '불임 원인 - 정자 농도', '불임 원인 - 정자 면역학적 요인', '불임 원인 - 정자 운동성', '불임 원인 - 정자 형태'
]

group4_cols = [
    '시술 시기 코드', '시술 당시 나이', '총 시술 횟수', '클리닉 내 총 시술 횟수', 'IVF 시술 횟수',
    'DI 시술 횟수', '총 임신 횟수', 'IVF 임신 횟수', 'DI 임신 횟수', '총 출산 횟수',
    'IVF 출산 횟수', 'DI 출산 횟수', '난자 출처', '정자 출처', '난자 기증자 나이', '정자 기증자 나이', 'ID'
]

```

# Group 1 시술 과정 및 타임라인 - 결측치 처리

시술 방법, 배란 유도 유형 및 단계별 경과일 중심 변수

| 컬럼명 | 결측치 개수(결측률) | 결측치 의미 | 대체값 |
|---|---|---|---|
| **임신 시도 또는 마지막 임신 경과 연수** | 246,981 (96.34%) | 첫 임신 시도라서 해당 없음"으로 단순 판단하기엔, 총 임신 횟수·총 시술 횟수가 1회 이상인데도 이 값이 결측인 케이스가 존재해 결측 발생 사유가 균일하지 않음 | **컬럼 삭제** |
| **특정 시술 유형** | 2 (0.00%) | 의미 x | IVF |
| **착상 전 유전 검사 사용 여부(PGS)** | 253,633 (98.94%) | 결과값이 1.0밖에 없음 = 결측치는 모두 시행 x | 0 |
| **착상 전 유전 진단 사용 여부(PGD)** | 6,291 (2.45%) | 시술 유형이 DI(자연 수정이기 때문에 배아 검사 불가) | 0 |
| **PGD 시술 여부**<br>**PGS 시술 여부** | 254,172 (99.15%)<br>254,422 (99.25%) | 이미 존재하는 '착상 전 유전 진단/검사 여부'와 중복되는 정보 | **컬럼 삭제** |
| **난자 채취 경과일** | 57,488 (22.43%) | 시술 당일 난자 채취 하지 않음<br>= 동결/기증 배아 이식 or<br>기증 제공된 난자로 신선 배아 이식 or 기존에 동결 난자 해동 후 신선 배아 생성 | '수집된 신선 난자 수'가 1 이상이고,<br>난자 출처가 '본인 제공'이면 0.0으로 결측치 대체(14건)<br>그 외에는 결측으로 두기 |
| **난자 해동 경과일** | 254,915 (99.44%) | 시술 당일 난자 해동 하지 않음<br>=동결/기증 배아 이식 or 당일 난자 채취 후 신선 배아 생성 | '해동 난자 수'가 1 이상일 시 0.0으로 결측치 대체(11건)<br>그 외는 결측으로 두기 |
| **난자 혼합 경과일** | 53,735 (20.96%) | 시술 당일 난자 혼합 하지 않음<br>= 동결/기증 배아 이식 | '혼합된 난자 수'가 1 이상일 시 0.0으로 결측치 대체(832건)<br>그 외는 결측으로 두기 |
| **배아 이식 경과일** | 43 566 (16.99%) | 시술 당일 배아 이식 하지 않음 | '이식된 배아 수'가 1 이상일 시 3.0으로 결측치 대체(740건)<br>그 외는 결측으로 두기 |
| **배아 해동 경과일** | 215,982 (84.25%) | 시술 당일 배아 해동 하지 않음 | '해동된 배아 수'가 1 이상일 시 0.0으로 결측치 대체(19건)<br>그 외는 결측으로 두기 |
| **단일 배아 이식 여부** | 6,291 (2.45%) | 시술 유형이 DI (자연수정이므로 배아 이식 x) | 0 |
| **동결 배아 이식 여부** | 6,291 (2.45%) | 시술 유형이 DI (자연수정이므로 배아 이식 x) | 0 |
| **신선 배아 이식 여부** | 6,291 (2.45%) | 시술 유형이 DI (자연수정이므로 배아 이식 x) | 0 |
| **기증 배아 이식 여부** | 6,291 (2.45%) | 시술 유형이 DI (자연수정이므로 배아 이식 x) | 0 |

# Group 1 시술 과정 및 타임라인-파생 변수 설정

### 🌟중요 변수

- 배아 이식 경과일
  - 3일 배양 (난할기)
  - 5일 배양 (배반포)

- **배반포까지 배양하는 이유**
  1. 자연 임신과 유사 : 체내 착상 시점과 유사하여 성공률 향상
  2. 자연 선택 효과 : 염색체 이상 등 발달 능력이 떨어지는 배아는 배반포까지 성장 X
  3. 유전 검사 안전성 : 착상 전 유전검사(PGS, PGD) 시 배아 손상 없이 세포 채취하기 가장 안전한 시점

### 🌟파생변수 생성

- **이식 경과일** : 5일 이상 배양 시 배반포 단계 - 성공률 증가
  - 해동 이식 경과일
  - 혼합 이식 경과일
  - 배반포 이식 여부
- **고령 여부, 고령 단일 배아 이식, 고령 배반포 배아 이식**

### ❗고령 여부와 관련된 파생 변수 실험 결과

**배경 : 고령 임신 시 염색체 분열 오류 증가 (난자의 cohesin 단백질의 노화로 인한 염색체 분열 오류)**
**만 35세 이상은 배반포 배아 2개까지 이식 가능하지만 단일 배아 이식을 선택했다는 것은 착상 성공률이 높다고 판단**

위 가설을 바탕으로 고령 관련 파생 변수 세 가지를 생성했으나, 실제 검증 결과 예측 성능에 유의미한 기여 X (제거 시 오히려 소폭 상승)

이는 '시술 당시 나이', '단일 배아 이식 여부', '배반포 이식 여부' 원본 컬럼만으로도
트리 기반 모델이 해당 상호작용을 스스로 학습 가능하기 때문으로 해석되어, **최종 모델에서는 제거**

# Group 2: 난자 및 배아 수량/과정 데이터

## 🌟결측치 처리

- **DI(인공수정) 시술 건수(6,291건)와 Group 2 결측치 일치**
  : 인공수정 특성상 난자 채취/배아 수정 과정이 없어 기록 부재
  - **수치형**: 난자/배아 관련 14개 변수 NaN를 **0**으로 대치
  - **범주형**: 배아 생성 이유, 시술 유형 ➡ '**알수없음**'으로 채움

- 대리모 여부 ➡ 0으로 대치

## 🌟파생변수 생성

- **총 활용 난자수** : 수집된 신선 난자 수 + 해동 난자 수
- **배아 생성률** : 총 생성 배아 수 / 총 활용 난자수
- **ICSI 성공률** : 미세주입 생성 배아 / 미세주입 난자 수
- **배아 이식률** : 생성된 배아의 이식 배분 비중
- **배아 저장률** : 생성된 배아의 동결 배분 비중

#생성된 배아 중 최상급 배아는 바로 이식(이식률)되고, 남은 우수 배아는 동결(저장률)

## ❗이상치 분석: 난소과자극증후군 사례 보존

### 의학적 배경 및 실제 사례 🔍

- 과배란 유도에 과도 반응하여 난자가 30~50개 채취되는 실제 고위험군 사례 존재
- 단순 입력 오류가 아닌 '극단적 생체 반응'을 보인 유의미한 데이터 패턴

데이터 활용 전략

- 난소과자극증후군 부작용으로 인한 이식 실패/동결 전환 등 부정적 패턴 학습 필요

➡이상치를 제거하지 않고 보존하여 모델이 핵심적인 위험/실패 패턴을 인지 하도록 유도

=== Group 2 수치형 이상치(통계 요약) 현황 ===

| | mean | 50% | max | std |
|---|---|---|---|---|
| 총 생성 배아 수 | 5.061145 | 4.0 | 51.0 | 4.664337 |
| 미세주입된 난자 수 | 4.170799 | 0.0 | 51.0 | 5.625943 |
| 미세주입에서 생성된 배아 수 | 2.843650 | 0.0 | 43.0 | 4.094640 |
| 이식된 배아 수 | 1.368156 | 1.0 | 3.0 | 0.771961 |
| 미세주입 배아 이식 수 | 0.724718 | 0.0 | 3.0 | 0.894352 |
| 저장된 배아 수 | 1.185975 | 0.0 | 51.0 | 2.502318 |
| 미세주입 후 저장된 배아 수 | 0.612933 | 0.0 | 51.0 | 1.842522 |
| 해동된 배아 수 | 0.454571 | 0.0 | 32.0 | 1.415320 |
| 해동 난자 수 | 0.046401 | 0.0 | 36.0 | 0.688246 |
| 수집된 신선 난자 수 | 8.563717 | 8.0 | 51.0 | 7.317230 |
| 저장된 신선 난자 수 | 0.093418 | 0.0 | 51.0 | 1.105882 |
| 혼합된 난자 수 | 7.698928 | 7.0 | 51.0 | 6.451914 |
| 파트너 정자와 혼합된 난자 수 | 7.107326 | 6.0 | 51.0 | 6.532466 |
| 기증자 정자와 혼합된 난자 수 | 0.534728 | 0.0 | 50.0 | 2.509487 |

# Group 3: 불임 원인 및 요인 분석

남성·여성·부부별 의학적 진단 요인 및 세부 원인 변수

## 🧹희소 변수 정제 및 삭제

- **여성 요인/자궁경부 문제 처리**
  - 여성 요인: 분산 0인 무의미한 변수 제거
  - 자궁경부 문제: 표본 부족(10건)에 따른 과적합 및 노이즈 방지를 위해 삭제

- **정자 세부원인 4종 원본 제거**
  - 농도, 운동성, 형태, 면역학적 요인
  - 개별 표본 수 부족으로 원본 삭제 후 통합 파생변수로 흡수/요약 처리

## 🌟파생변수 생성

- **남성세부원인_명시** (Binary)
  - 로직: max(농도, 운동성, 형태, 면역)
  - 의미: 구체적 정자 이상 요인 기록 여부

- **남성세부원인_개수** (Numeric)
  - 로직: sum(농도, 운동성, 형태, 면역)
  - 의미: 이상 요인의 중복 결합 개수(이론상: 0~4 실측 최댓값: 3)

## ❗의학적/임상적 근거

**OAT** : 농도 이상(Oligo) + 운동성 이상(Astheno) + 형태 이상(Terato)이 겹친 상태 (겹치는 개수가 많을수록 중증도 ⬆)
- 정자 생성과정은 호르몬조절, 유전적신호, 최적 고환온도에 의존하는 매우 정교한 과정이라, 어느 부분이든 무너지면 세 지표가 동시에 떨어지는 양상을 보임
  1개: 24.5% (n=372) ➡ 2개: 20.7% (n=29) ➡ 3개: 17.2% (n=29)
- 면역학적 요인은 OAT의 직접 구성요소는 아니나, 표본이 1건뿐이라 단독 사용이 불가능해 동일 계열(정자 관련 세부원인)로 통합

**정보성 결측 (Informative Missingness) :** 기록 유무 자체가 임상의의 진단 의도를 담은 신호 ➡ 단순 삭제 대신 기록 유무를 파생변수화하여 임상 신호 보존
**명시군(23.7%, n=430) vs 미명시군(28.0%, n=95k) vs 남성요인없음(24.6%, n=160k)**

# Group 4: 환자 이력 및 인적 정보

환자/기증자 연령 및 과거 시술·임신·출산 이력 데이터

## 🌟데이터 전처리 (인코딩 & 수치화)

- **시술/임신/출산 횟수 수치형 변환**
  - '회', '회 이상' 등의 문자열 단위 제거 후 정수형(int) 변환
  - 대상 변수: 총 시술/임신/출산 횟수, IVF/DI 시술,임신,출산 횟수 등 10개 피처
- **범주형 피처 인코딩 (Ordinal & Label Encoding)**
  - 시술 당시 나이: 연령대 순서를 반영하여 서열형 인코딩 (0~6)
  - 기증자 나이: 난자/정자 기증자 연령대를 서열형 인코딩
    (결측 및 미제공 값은 0/음수값 처리)
  - 시술 시기 코드 및 출처: 암호화된 코드 및 출처(난자/정자) 레이블 인코딩

## 🌟파생변수 생성

**난자/정자 기증 여부**

: 기증자 나이 데이터의 '알 수 없음' 유무를 바탕으로 실제 기증 수술 여부(0/1) 파생변수 추출

## ❗결측치 및 데이터 특성 점검

### 데이터 완전성 확인 🔍

- 결측치 0건: group 4 내 모든 컬럼의 Train/Test 결측치 수 0개 확인
- 데이터 일관성: 문자열 형태의 범주형/순서형 데이터를 모델이 학습 가능한 규격화된 수치 데이터로 완벽 변환 완료

```
# group4_cols 컬럼별 타입 확인
print(train_prep[group4_cols].dtypes)
```

```
시술 시기 코드          int64
시술 당시 나이        float64
총 시술 횟수            int64
클리닉 내 총 시술 횟수    int64
IVF 시술 횟수          int64
DI 시술 횟수           int64
총 임신 횟수            int64
IVF 임신 횟수          int64
DI 임신 횟수           int64
총 출산 횟수            int64
IVF 출산 횟수          int64
DI 출산 횟수           int64
난자 출처              int64
정자 출처              int64
난자 기증자 나이       float64
정자 기증자 나이       float64
ID                    object
dtype: object
```

# 모델링 및 성능 향상 전략

다양한 머신러닝 알고리즘 적용 및 하이퍼파라미터 튜닝을 통한 성능 향상

## 분류 모델 적용

초기 모델을 난임 데이터의 비선형 패턴 학습에 유리한 **XGBoost**를 베이스라인으로 선정

**데이터 기본 예측 성능 및 클래스 불균형 영향력 진단**

## 하이퍼파라미터 튜닝

**단계적 탐색**
Randomized Search (광범위 탐색)
➡Optuna(베이지안 정밀 최적화) 순차 적용

**핵심 인자 최적화**
learning_rate, max_depth, subsample 등을 정밀 조절

**소수 클래스 가중치 최적화를 통해 클래스 예측력 극대화**

## 모델 비교 및 향상

**다중 알고리즘 확장**
LightGBM, CatBoost 모델 추가 및 튜닝

**핵심 평가 지표(Metric) 분석**
- AUC-ROC
  : 전체적인 분류 성능 및 변별력 확인
- Recall & F1-Score
  : 실제 임신 성공(Class 1) 예측력 평가

**Stratified 5-Fold & OOF 적용**
검증 체계 구축, 데이터 누수 방지

**Trouble Shooting**(모델링 정체 시)
파이프라인 재점검 및 피처 재강화

📌**최종 모델링 목표**
**분류 임계값 (Threshold) 최적화 및 앙상블 적용**

# 모델링 세부 실행 이정표

XGBoost부터 Trouble Shooting까지의 단계별 파이프라인

### 01. XGBoost Baseline

초기 베이스라인 및 문제 진단

기본 모델 구축 및 성과 측정
• Class 1 Recall값 식별
• Randomized Search & Optuna 튜닝

### 02. LightGBM

고성능 트리 모델 벤치마킹

• fast & high efficiency 학습
• 파라미터 조절
• Class 1 Recall 향상 검증

### 03. Threshold 최적화

임계값 조정을 통한 지표 극대화

Precision-Recall Curve 분석 및 5-Fold Cross-Validation 기반 최적 Cut-off 스캔

### 04. CatBoost

범주형 피처 특화 모델 확장

CatBoostClassifier 단일 변수 스캔 후 Optuna 베이지안 탐색

### 05. Trouble Shooting

시행착오 극복 및 성능 향상

모델 정체기 진단 후 누락 데이터 확인 및 파생변수 재강화 후 성능 실험

# 초기 XGBoost Baseline 모델링 및 성능 평가

## 데이터 전처리 (Preprocessing)

**범주형 피처 인코딩 (Ordinal Encoding)**

object 및 category 타입 컬럼을
정수형/수치형으로 일괄변환

**OrdinalEncoder 활용**
handle_unknown='use_encoded_value',
unknown_value=-1
설정으로 미학습 범주 예외 처리

## 베이스라인 모델 구축

**기본 모델 설정**

XGBClassifier(random_state=42)
기본 파라미터 적용

- **검증 데이터 분할 (Train/Validation Split)**
- 전체 학습 데이터를 **80:20** 비율로 분할 (test_size=0.2)

타겟 불균형 보완을 위해
**층화 추출(stratify=y_train)** 적용

## 초기 모델 평가 요약 및 한계점

**=== 📊 모델 검증 평가 결과 ===**
**ROC-AUC Score : 0.7325 Accuracy : 0.7438 F1-Score : 0.2186**

**📌 핵심 문제점 (Class 1 불균형)**

**Low Recall (0.14):** 실제 임신 성공 (Class 1) 사례 중 14%만 감지하는 재현율 저하 발생

**원인:** 기본 임계값(0.5) 사용 및 클래스 불균형 미처리로 인해 모델이 대부분을 실패(Class 0)로 예측

✨개선 방향: **하이퍼파라미터 최적화**

# 📝 XGBoost 모델링 및 최적화 전략

Randomized Search & Optuna 하이퍼파라미터 최적화와 K-Fold OOF를 통한 모델 성능 고도화 및 일반화 확보

## 1. 하이퍼파라미터 최적화 (Randomized Search)

Category 타입 자동 변환 및 불균형 가중치(scale_pos_weight) 탐색

**최적 조합:** scale_pos_weight: 1.0, learning_rate: 0.05, max_depth: 6

n_estimators: 300,

min_child_weight(3), subsample(0.8), colsample_bytree(0.8) 조정

## 2. 과적합 방지 및 안정성 확보

**colsample_bytree=0.8** : 피처 무작위 샘플링으로 과적합 차단

**Stratified K-Fold (n_splits=5)** 교차 검증 적용으로 평가 신뢰도 확보

**Out-of-Fold (OOF) 예측**: 검증 데이터 손실 없이 모델 일반화 성능 평가

## 핵심 평가 지표 및 모델 성능

| metric | baseline(XGB) | Randomized Search |
|---|---|---|
| ROC-AUC | 0.7325 | 0.7363(+0.0038) |

-

**상세 평가**

Accuracy: 0.7456

Class 1 (임신 성공): Precision: 0.53 / **Recall: 0.13** / F1: 0.20

Class 0 (임신 실패): Precision: 0.76 / Recall: 0.96 / F1: 0.85

# 📝 XGBoost 모델링 및 최적화 전략

Randomized Search & Optuna 하이퍼파라미터 최적화와 K-Fold OOF를 통한 모델 성능 고도화 및 일반화 확보

## Optuna 기반 베이지안 하이퍼파라미터 최적화

베이지안 최적화(Bayesian Optimization): 이전 시도 결과를 반영하여 파라미터 탐색 공간 정밀 탐색

**Optuna 최적 조합**: scale_pos_weight: 1.78, learning_rate: 0.0355, max_depth: 5, n_estimators: 232 , subsample(0.67), colsample_bytree(0.97), min_child_weight(4) 세밀 조정

## 과적합 방지 및 안정성 확보

**Stratified K-Fold (n_splits=5)**: 클래스 비율을 유지한 5개 교차 검증으로 데이터 누수(Leakage) 차단

**Out-of-Fold (OOF) 예측**: 5개 Fold의 예측 확률을 평균(Soft Voting)하여 제출 데이터에 대한 분산(Variance) 최소화

**안정적인 검증 구조**: Validation Score와 Test Score 간 격차를 최소화하여 리더보드 셰이크다운 예방

## 핵심 평가 지표 및 모델 성능

| metric | baseline(XGB) | optuna |
|---|---|---|
| ROC-AUC | 0.7325 | 0.7396 (+0.0071) |

-

**상세 평가**

Accuracy: 0.7127

Class 1 (임신 성공): Precision: 0.45 / **Recall: 0.49** / F1: 0.47

Class 0 (임신 실패): Precision: 0.82 / Recall: 0.79 / F1: 0.80

# 📝 XGBoost 모델링 및 최적화 전략

Randomized Search & Optuna 하이퍼파라미터 최적화와 K-Fold OOF를 통한 모델 성능 고도화 및 일반화 확보

**탐색 기법 효율성 :** 무작위 탐색(Random Search)으로 빠르게 범위를 좁힌 후, Optuna로 세밀한 최적점 도출

**클래스 불균형 조정 영향 :** scale_pos_weight를 **1.0 → 1.78**로 최적화하여 소수 클래스 가중치 부여
임신 성공(Class 1) 감지 능력(Recall)이 **0.14→ 0.13 → 0.4934**로 약 **3.8배 상승**하며
소수 클래스 예측력 극대화

**최종 평가 결과 : Baseline (0.7325) ➡ Randomized Search (0.7363) ➡ Optuna (0.7396)**
K-Fold OOF 앙상블을 함께 적용하여 **단계적 ROC-AUC 우상향 달성** 및 일반화 성능 확보

# 📝 LightGBM 모델링 및 최적화 전략

그리드 서치와 K-Fold OOF를 통한 모델 성능 고도화 및 일반화 확보

## 1. 하이퍼파라미터 최적화 (Grid Search)

- Category 타입 자동 변환을 통한 범주형 피처 처리 최적화
- **3-Fold Grid Search를 통한 16가지 파라미터 조합 체계적 탐색**🔎
- **최적 조합:** learning_rate: 0.03, max_depth: 7, n_estimators: 300
- 데이터 특성에 맞춰 min_child_samples(50),num_leaves(63) 조정

## 2. 과적합 방지 및 안정성 확보

- **subsample_freq=1** : 매 트리 생성 시 80% 무작위 샘플링 스위치 작동
- **min_child_samples=50** : 노드당 최소 데이터 제한으로 노이즈 학습 차단
- **Stratified K-Fold (n_splits=5)** 적용을 통한 교차 검증 및 일반화 성능 확보 명시.

## 핵심 평가 지표 및 모델 성능

| metric | baseline(XGB) | lightGBM |
|---|---|---|
| ROC-AUC | 0.7325 | 0.7368(+0.0043) |
| Recall (Class 1) | -0.1400 | 0.7700(+0.6300) |

**상세 평가**

- Accuracy: 0.6228
- Class 1 Precision: 0.38 / **Recall: 0.77** / F1: 0.51
- Class 0 Precision: 0.88 / Recall: 0.57 / F1: 0.69

💡 LightGBM 적용으로 Overall AUC 개선 및 **임신 성공(Class 1)의 Recall을 0.14에서 0.77**로 향상하여 실제 예측 실효성 확보

# 📝 분류 임계값(Threshold) 최적화 전략

확률 임계값 조정을 통한 임신 성공(Class 1) 예측 성능 및 실효성 극대화

## 1. 임계값 최적화 (Threshold Tuning) 필요성

- **기존 방식의 한계:** 불균형 데이터셋에서 기본 임계값(0.5) 적용 시 Class 1 예측 민감도 저하
- **목적 함수 설정:** 단순 정확도(Accuracy) 대신 F1-Score 및 Recall (Class 1)을극대화하는 구간 탐색
- **비대칭 손실 반영:** 임신 성공 건을 놓치는 위험(False Negative)을 최소화 하기 위한 판정 기준 완화

## 2. 최적 임계값 탐색 및 적용

- **Precision-Recall Curve 분석:** 0.01 단위 스캔으로 최적 임계값 0.246 도출
- **Class 1 Recall 대폭 향상:** 기존 0.14 → 0.7959 (약 5.7배 증가)
- **실제 감지 건수(TP) 비교 (총 13,246건 중):**
  기존 (0.5): **1,854건** 감지 → 개선(0.246): **10,544건** 감지 **(+8,690건)**

## 핵심 평가 지표 및 모델 성능

| Metric | Baseline (Threshold 0.5) | Optimized Threshold |
|---|---|---|
| F1-Score (Class 1) | 0.2139 | 0.5130 |
| Recall (Class 1) | 0.1400 | 0.7959 |
| ROC-AUC | 0.7325 | 0.7325 |

**상세 평가**

- ROC-AUC: 0.7325 (K-Fold OOF 평균 변별력 유지)
- Accuracy: 0.6096
- Class 1 Precision: 0.3785 / Recall: 0.7959 / F1: 0.5130
- Class 0 Precision: 0.8846 / Recall: 0.5447 / F1: 0.6742

💡5-Fold 교차 검증을 통해 과적합 없는 **최적 임계값(0.246)**을 도출,
**임신 성공(Class 1) Recall을 0.7959까지 극대화**하여 실효성 높은 난임 예측 모델을 구현

# 📝 CatBoost 최적화 전략

Optuna 기반 하이퍼파라미터 탐색과 K-Fold OOF를 통한 모델 성능 고도화

## 1. 모델 특성 탐색: 단일 변수 실험

• **초기 조건 설정:** depth=6, learning_rate=0.05, iterations=1,000 기반 단일 실험 수행(**ROC-AUC 0.7375**) • learning rate, depth, 범주형 처리 방식을 하나씩 변경하여 영향 확인

• **한계점 파악:** 주요 파라미터 단독 변경 시 **0.7367~0.7375** 범위에서 성능 정체

## 2. 탐색 확장: Optuna 조합 최적화

• **복합 파라미터 탐색:** 모델 복잡도(depth), 학습 강도(learning_rate), 과적합 억제(l2_leaf_reg), 분할 무작위성(random_strength)을 주요 탐색 변수로 선정

• **단계별 정밀 스캔:** 1차 광범위 탐색 후 depth=7 고정, 2차 정밀 탐색을 통해 최적 조합 확정

## 핵심 평가 지표 및 모델 성능

| 실험 단계 | ROC-AUC | AUC 변화량 |
|---|---|---|
| XGBoost | 0.7325 | - |
| CatBoost 1차 | 0.7375 | + 0.0050 |
| CatBoost 2차 | 0.7377 | + 0.0052 |

### 최종 Optuna 적용 조건

• depth: **7** / learning_rate: **0.03445**
• l2_leaf_reg: **8.582** / random_strength: **0.549**
• 최대 iterations: **1–1,000** / Best iteration: **471**
• 1차·2차 탐색 최고 AUC: **0.737702로 동일**

💡 **CatBoost 및 Optuna 조합 최적화를 통해 Overall AUC를 0.7377로 개선**

# 📝 파생변수 적용 및 performance 개선 시행착오

Trial & Error

## 1. 주요 문제 상황

- **group 1~4 전체에 대해 파생변수를 생성하여 모델 성능 향상을 시도**
- **베이스라인 비교 (원본 데이터 전처리)**
  - 원본 데이터 기반 ROC-AUC: 0.73985
  - 파생변수 적용 후 ROC-AUC: 0.73981 (오히려 0.00004 하락)

## 2. 원인 분석 (Cause Analysis)

- **파생변수 코드 누락 발견**
  - 파생변수 전처리 파이프라인 검증 중 **group 1의 데이터 전처리 및 파생변수 생성 코드가 누락**된 것을 확인
  - group 1 전처리의 부재가 전체 모델의 특징 표현(Feature Representation) 역량을 저하시킨 주요 원인으로 규명

## 3. 해결 과정

- **정상화 및 추가 피처 엔지니어링:**
  - Step 1: Group 1 전처리 코드 정상화 및 파생변수 복원
  - Step 2: Group 1 대상 신규 파생변수 3개 추가 정의 (피처 강화)
- **단계별 성능 평가:**
  - Step 1 적용 후 ROC-AUC: **0.73987 (반등)**
  - Step 2 적용 후 ROC-AUC: **0.73991 (최고 성능)**

**[베이스라인] 원본 전처리만 적용**
└── 0.7325

**[시도 1] 그룹 1 전처리 누락 수정 + 전 그룹 파생변수 복원**
└── 0.73987 (+0.00002) 🟢 **반등 성공**

**[시도 2] 그룹 1 대상 신규 파생변수 3개 추가 정의**
└── 0.73991 (+0.00004) 🚀 **최고 성능 달성**

💡 **데이터 전처리 누락 수정 및 group 1 파생변수 강화를 통해 모델의 예측 성능 달성 (0.73991)**

# 📝 최적기법 탐색/다중 알고리즘 결합을 통한 최적의 예측 모델 구축

“ 단일 모델의 한계를 넘어 예측 안정성과 성능을 더 올릴 수 없을까? ”

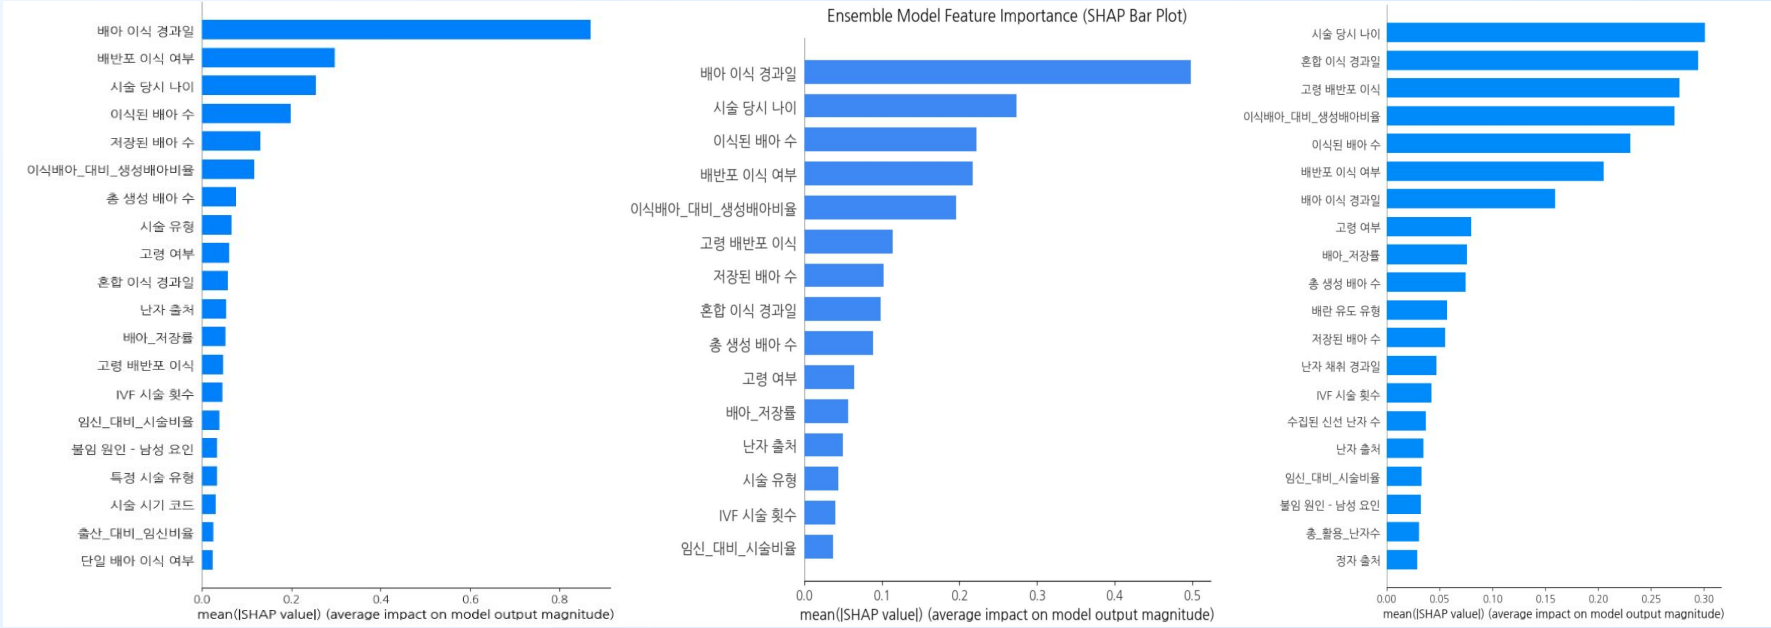
| 모델명 | 기본 모델 (random_state =42) | 수동 하이퍼파라미터 (BAIB 기본 코드) | Gridsearch, Randomsearch 적용 | Optuna 적용 (3fold, 30trial) | Optuna 적용 (3fold, 50trial > 5fold 정밀 탐색) | LightGBM, XGBoost - Optuna, CatBoost - 수동 |
|---|---|---|---|---|---|---|
| LightGBM | 0.73941 | 0.74019 | 0.73971 | 0.73999 | 0.740406 | |
| XGBoost | 0.73581 | 0.73991 | 0.73968 | 0.73845 | 0.740339 | |
| CatBoost | 0.73963 | 0.740142 | - | 0.73998 | 0.740009 | |
| 가중평균 | | 0.74049 | | | | 0.740618 |
| 로짓평균 | | | | | | 0.740618 |
| 기하평균 | | | | | | 0.740617 |
| Rank | | | | | | **0.740624** |
| Power | | | | | | 0.740621 |
| 스태킹 | | 0.74045 | | | | 0.740604 |
| 최고 성능 | **0.73963** | **0.74049** | **0.73971** | **0.73999** | **0.740406** | **0.740624** |

➡ 가장 성능이 우수했던 Rank Averaging 방식을 최종 앙상블 모델로 채택

# 📝 핵심 변수 도출 및 임상적 기대효과

데이터 기반 진료 체계 구축을 위한 SHAP 막대그래프를 통한 주요 지표 도출

## 1.핵심 변수 중요도(Lightgbm - ensemble - catboost 순)




**- 최종 예측 모델 채택**

: *실제 진료 현장에서 환자의 임신 성공 확률을 가장 높은 정확도와 안정성으로 예측하기 위해* ***최종 모델로는 블렌딩 모델중 랭크 에버리징모델을 채택***

**- 모델 해석 및 변수 영향력 분석 (SHAP) :** *복잡한 앙상블 구조에서의 변수별 기여도와 임상적 방향성을 정밀하게 해석하기 위해, 단일 모델 중 성능이 가장 뛰어났던* ***LightGBM을 기반으로 TreeSHAP 분석을 수행****하여 핵심 변수들의 영향력을 도출*

# 📝 핵심 변수 분석 기반 임상적 활용(1)

도출된 핵심 변수 기반 진료 적용 방안 및 임상적 기대효과

### 환자 맞춤 시술 계획 수립

• 배아 이식 경과일, 배반포 이식 여부, 혼합 이식 경과일이 하나의 신호 (이식지점/배반포 단계)로 확인됨

→ 배양 일수와 이식 지점을 환자 상태에 맞춰 사전 설계하는 프로토콜 수립 가능

### 시술 실패 위험 사전 차단 (고위험군 조기 관리)

• 성공 확률이 낮은 환자를 사전에 파악하여, 불필요한 시술 반복을 줄이고 대안 치료법을 선제적 제안

→ 고령 환자군을 시술 전단계에서 조기 식별해 성공률 낮은 반복시술을 줄이고 대안 치료법으로 선제적 제안과 환자의 안전을 위한 불필요한 리스크를 예방할수 있습니다.

# 📝 핵심 변수 분석 기반 임상적 활용(2)

도출된 핵심 변수 기반 진료 적용 방안 및 임상적 기대효과

### 의료진 의사결정 보조 (데이터 기반 진료)

• 기존의 도메인 지식에 객관적인 AI 성공 확률 데이터를 더해 진료의 정확도와 신뢰성을 향상시킬 수 있습니다.

→ 여러 지표를 개별적으로 확인하지 않아도 핵심 지표 중심으로 배아 상태를 빠르게 판단하고 결정할수 있습니다.

※ 다만 본 모델은 의료진의 판단을 대체하는 것이 아닌 보조 수단이며, 최종 진단 및 치료 방침에 대한 결정과 책임은 담당 의료진에게 있음을 유의할 필요가 있습니다.

### 모델 적용이후 바뀌는 AI동반진료 워크플로우✨

**09:00**

신규 환자 내원 → AI가 SHAP 기반 성공 확률 즉시 산출, 고위험군 조기 식별

**10:00**

시술 계획 회의 → 조정 가능한 배아 이식 지점, 배반포 단계를 환자 상태에 맞춰 시뮬레이션

**14:00**

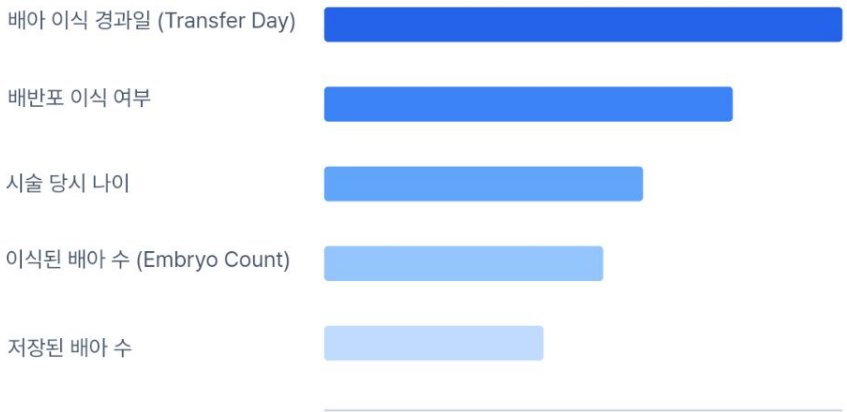
배아배양 결과 검토 → 총 생성 배아수, 저장률 등 지표를 데이터와 도메인지식을 곁들여서 판단

**16:00**

이식개수 최종 상담 → 1개이식 vs 2개이식 시 예상 성공률 비교 제시, 환자와 함께 1:1 개인형 프로토콜 확정

# 머신러닝 모델링 성능 평가

## Top5 Feature Importance (SHAP Value)




### 📌 LightGBM 단일 모델 선정

최종 모델은 블렌딩 모델 중 랭크에버리징 모델인데 새로운 모델을 학습하는 게 아니라,
학습이 끝난 3개 단일 모델의 예측확률값을 랭크 에버리징한 것이기 때문에
단일 모델 중 성능이 가장 좋았던 **LightGBM에서 중요변수를 선정**했습니다.

### 최적의 앙상블

- 모델: XGBoost, LightGBM, CatBoost
- 5가지 블렌딩 기법과 스태킹을 통한 최종 예측 안정성 확보

### 핵심 변수

- 5-Fold Stratified Cross-Validation으로 과적합 방지
- Feature Importance 분석을 통한 임신 성공 핵심 변수 도출
- **optuna를 통해 최적의 하이퍼파라미터 발견**

ROC-AUC Score

🚀 **0.7325 -> 0.7406**

# 경청해 주셔서 감사합니다

Q & A